

빅데이터 분석 정의서

과제명 : 실시간 뉴스 크롤링을 활용한 TextRank-KoBART
모델기반 요약뉴스 서비스 "삼삼뉴스"

2023.06.16.

팀명: 삼삼호호

I. 개요

1. 아이디어 주제

: 실시간 뉴스 크롤링을 활용한 TextRank-koBART모델기반 요약뉴스 서비스

2. 개발 목표

: 원하는 뉴스를 찾거나 관련 뉴스를 추천해주는 서비스

3. 개발 내용

: 키워드를 사용한 wordcloud

: 뉴스 요약 서비스

II. 기능별 빅데이터 분석 명세서

기능명	키워드를 사용한 wordcloud																																																																								
1. 데이터 준비																																																																									
데이터 정의	사용자 입력 데이터, 뉴스 데이터(뉴스 기사, 기자 정보, 출판사 정보, 뉴스 카테고리, 키워드), 사용자 프로필 데이터(사용자의 선호 카테고리, 이전 기록, 구독 정보)																																																																								
데이터 획득 방법	신문사별 뉴스 하루 약 200개 정도 크롤링(총합 약 1000개) 한겨레(https://www.hani.co.kr/), 경향신문(https://www.khan.co.kr/), 중앙일보(https://www.joongang.co.kr/), 동아일보(https://www.donga.com/), 조선일보(https://www.chosun.com/)																																																																								
수집 데이터	신문사, 날짜(YYYY-MM-DD), 카테고리(경제, 사회, 문화 등), 기사제목, 기사내용 <table><tr><th>press</th><th>category</th><th>title</th><th>date</th><th>reporter</th><th>content</th></tr><tr><td>조선일보</td><td>경제</td><td>누누티비 차단 효과? 트루 OTT 플랫폼 사용자 수 100만명 증가</td><td>2023.06.07</td><td>채재우 기자</td><td>[출판사별] 스트리밍 사이트 누누티비가 국내 온라인 동영상 서비스(OTT) 플랫폼 중...</td></tr><tr><td>조선일보</td><td>경제</td><td>"이번 학기도 힘주고 하셨다" 대학가에 불은 장문사 포스터</td><td>2023.06.07</td><td>김자아 기자</td><td>[국내 한 저비용항공사(LCC)가 대학가를 대상으로 무료당근 행사를 진행한다고 ...</td></tr><tr><td>조선일보</td><td>경제</td><td>중대재해처벌 위험성 평가가 현실... 주 처벌 대상은 대표이사</td><td>2023.06.07</td><td>류정 기자</td><td>[중대재해처벌법에 따른 처벌의 핵심 기준은 기업들이 자체적으로 위험성 평가를 제...</td></tr><tr><td>조선일보</td><td>경제</td><td>한강류 아파트 59㎡가 8억7000만원... 이달 얼마 공공분양 돌아간다</td><td>2023.06.07</td><td>신수지 기자</td><td>[시세보다 한 가격에 내 집 마련이 가능한 공공분양] 뉴스를 통해 사전예약...</td></tr><tr><td>조선일보</td><td>경제</td><td>'출원 기원발'가 '프리카' 유튜브로 유통... 웹사이트에 올 사용자 역대 최대</td><td>2023.06.07</td><td>김봉기 기자</td><td>[국내 출원서비스 업체에서 '출원 기원발'가 논란을 일으킨 구술 '유통'의 성...</td></tr><tr><td>...</td><td>...</td><td>...</td><td>...</td><td>...</td><td>...</td></tr><tr><td>경향신문</td><td>국제</td><td>'미 CIA, 우크라이나 해군 기지 공격 계획 3개월 전에 인지'</td><td>2023.06.07</td><td>선명수 기자</td><td>[미국 정보당국이 지난해 9월 발트해 해저 노르포트 기지 공격을 사전 3개월 전...</td></tr><tr><td>경향신문</td><td>국제</td><td>'이파네마의 소녀' 보사노바 가수 아스트루지 지우에르토 별세</td><td>2023.06.07</td><td>선명수 기자</td><td>[1900년대 '보사노바' 열풍을 일으킨 곡 '이파네마의 소녀(The Girl F...</td></tr><tr><td>경향신문</td><td>국제</td><td>'지안 공백' 아이티, 북미 이어 지진까지... 최소 55명 사망</td><td>2023.06.07</td><td>선명수 기자</td><td>[경한의 폭격과 전염병 확산 등으로 극심한 혼란을 겪고 있는 중남미 카리브해의 섬...</td></tr><tr><td>경향신문</td><td>국제</td><td>미·우크라이나 '루카' 나토 EU와 동맹... '루카' 나토 EU와 동맹</td><td>2023.06.07</td><td>선명수 기자</td><td>[미국이 6일(현지시간) 우크라이나 남부 헤르손주 카포우카에 루카의 배후를 아직...</td></tr><tr><td>경향신문</td><td>국제</td><td>한국 11년 만에 루에 아브라 비하</td><td>2023.06.07</td><td>정원식 기자</td><td>[한국은 6일(현지시간) 미국 뉴욕에서...</td></tr></table>	press	category	title	date	reporter	content	조선일보	경제	누누티비 차단 효과? 트루 OTT 플랫폼 사용자 수 100만명 증가	2023.06.07	채재우 기자	[출판사별] 스트리밍 사이트 누누티비가 국내 온라인 동영상 서비스(OTT) 플랫폼 중...	조선일보	경제	"이번 학기도 힘주고 하셨다" 대학가에 불은 장문사 포스터	2023.06.07	김자아 기자	[국내 한 저비용항공사(LCC)가 대학가를 대상으로 무료당근 행사를 진행한다고 ...	조선일보	경제	중대재해처벌 위험성 평가가 현실... 주 처벌 대상은 대표이사	2023.06.07	류정 기자	[중대재해처벌법에 따른 처벌의 핵심 기준은 기업들이 자체적으로 위험성 평가를 제...	조선일보	경제	한강류 아파트 59㎡가 8억7000만원... 이달 얼마 공공분양 돌아간다	2023.06.07	신수지 기자	[시세보다 한 가격에 내 집 마련이 가능한 공공분양] 뉴스를 통해 사전예약...	조선일보	경제	'출원 기원발'가 '프리카' 유튜브로 유통... 웹사이트에 올 사용자 역대 최대	2023.06.07	김봉기 기자	[국내 출원서비스 업체에서 '출원 기원발'가 논란을 일으킨 구술 '유통'의 성...	...	...	...	...	...	...	경향신문	국제	'미 CIA, 우크라이나 해군 기지 공격 계획 3개월 전에 인지'	2023.06.07	선명수 기자	[미국 정보당국이 지난해 9월 발트해 해저 노르포트 기지 공격을 사전 3개월 전...	경향신문	국제	'이파네마의 소녀' 보사노바 가수 아스트루지 지우에르토 별세	2023.06.07	선명수 기자	[1900년대 '보사노바' 열풍을 일으킨 곡 '이파네마의 소녀(The Girl F...	경향신문	국제	'지안 공백' 아이티, 북미 이어 지진까지... 최소 55명 사망	2023.06.07	선명수 기자	[경한의 폭격과 전염병 확산 등으로 극심한 혼란을 겪고 있는 중남미 카리브해의 섬...	경향신문	국제	미·우크라이나 '루카' 나토 EU와 동맹... '루카' 나토 EU와 동맹	2023.06.07	선명수 기자	[미국이 6일(현지시간) 우크라이나 남부 헤르손주 카포우카에 루카의 배후를 아직...	경향신문	국제	한국 11년 만에 루에 아브라 비하	2023.06.07	정원식 기자	[한국은 6일(현지시간) 미국 뉴욕에서...
press	category	title	date	reporter	content																																																																				
조선일보	경제	누누티비 차단 효과? 트루 OTT 플랫폼 사용자 수 100만명 증가	2023.06.07	채재우 기자	[출판사별] 스트리밍 사이트 누누티비가 국내 온라인 동영상 서비스(OTT) 플랫폼 중...																																																																				
조선일보	경제	"이번 학기도 힘주고 하셨다" 대학가에 불은 장문사 포스터	2023.06.07	김자아 기자	[국내 한 저비용항공사(LCC)가 대학가를 대상으로 무료당근 행사를 진행한다고 ...																																																																				
조선일보	경제	중대재해처벌 위험성 평가가 현실... 주 처벌 대상은 대표이사	2023.06.07	류정 기자	[중대재해처벌법에 따른 처벌의 핵심 기준은 기업들이 자체적으로 위험성 평가를 제...																																																																				
조선일보	경제	한강류 아파트 59㎡가 8억7000만원... 이달 얼마 공공분양 돌아간다	2023.06.07	신수지 기자	[시세보다 한 가격에 내 집 마련이 가능한 공공분양] 뉴스를 통해 사전예약...																																																																				
조선일보	경제	'출원 기원발'가 '프리카' 유튜브로 유통... 웹사이트에 올 사용자 역대 최대	2023.06.07	김봉기 기자	[국내 출원서비스 업체에서 '출원 기원발'가 논란을 일으킨 구술 '유통'의 성...																																																																				
...	...	...	...	...	...																																																																				
경향신문	국제	'미 CIA, 우크라이나 해군 기지 공격 계획 3개월 전에 인지'	2023.06.07	선명수 기자	[미국 정보당국이 지난해 9월 발트해 해저 노르포트 기지 공격을 사전 3개월 전...																																																																				
경향신문	국제	'이파네마의 소녀' 보사노바 가수 아스트루지 지우에르토 별세	2023.06.07	선명수 기자	[1900년대 '보사노바' 열풍을 일으킨 곡 '이파네마의 소녀(The Girl F...																																																																				
경향신문	국제	'지안 공백' 아이티, 북미 이어 지진까지... 최소 55명 사망	2023.06.07	선명수 기자	[경한의 폭격과 전염병 확산 등으로 극심한 혼란을 겪고 있는 중남미 카리브해의 섬...																																																																				
경향신문	국제	미·우크라이나 '루카' 나토 EU와 동맹... '루카' 나토 EU와 동맹	2023.06.07	선명수 기자	[미국이 6일(현지시간) 우크라이나 남부 헤르손주 카포우카에 루카의 배후를 아직...																																																																				
경향신문	국제	한국 11년 만에 루에 아브라 비하	2023.06.07	정원식 기자	[한국은 6일(현지시간) 미국 뉴욕에서...																																																																				

2. 전처리	
전처리 과정	1. 초기 크롤링 데이터를 mongoDB에 저장 2. 날짜별로 데이터를 불러옴 3. Dictionary 타입의 데이터를 DataFrame 타입으로 변환 4. kiwi라이브러리를 사용해서 기사별로 내용중 한국어 명사, 영어 단어, 한자만 추출후 저장
전처리 데이터	전처리 후 전체 데이터의 볼륨 - 총 1022개 기사데이터 각 데이터당 단어수 : 평균 591개 ['불법 동영상 스트리밍 사이트 누누티비 국내 온라인 동영상 서비스 OTT 종료 개월 토종 OTT 사용자 미성', '빅데이터 분석 플랫폼 모바일 인덱스 티빙 쿠팡 플레미 웨이브 왓챠 국내 OTT 개사 할간 활성 사용자 MAU' 집계', '모바일 시청자 분석 숫자 TV 플랫폼 규모 예상', '업계 추산 이용자 미성 누누티비 서비스 종료 영향', '서비스 시작 누누티비 도미니카공화국 해외 서버 국내 유료 OTT 지상파 신작 무료 제공', '정부 유관 기관 합동 수사 국제 공조 수사 확대 입장 서비스 종료', '업계 관계자 누누티비 시장 경쟁 과정 최근 국내 OTT 오리지널 콘텐츠 반을 독점 TV 프로그램 서비스 차별 집중 설명', '기간 종료별 OTT 업체 사용자', '기준 넷플릭스 전월 대비 디즈니 플러스 감소', '넷플릭스 글로벌 이후 화제 콘텐츠 영향 품어']
3. 데이터 분석	
데이터 분석 목표	카테고리별 중요단어를 한눈에 파악할 수 있는 wordcloud 만들기
데이터 분석 시나리오	의 키워드 1. CounterVectorizer로 각 기사에서 추출된 명사의 빈도수 파악 - ngram_range = (1,2) 2. TextRank로 명사별 가중치 파악 3. 가중치가 높은 상위 15개의 단어 추출 4. 기사별 추출된 중요단어 저장 5. 카테고리(사회, 경제, 정치, 국제)별로 중요단어 통합 6. 통합된 중요단어의 빈도수를 counter를 사용해서 계산 7. DataFrame에 저장 8. 빈도수가 많을 때 큰 크기를 보여주는 wordcloud제작

4. 검증	
데이터 분석 검증 방안	검증방법 - 실제 기사에서 포함된 주요 단어와 데이터 분석 결과로 나온 주요 단어를 비교해서 데이터 분석 결과의 성능을 파악 - 실제 기사에서 나온 중요단어 안에 데이터 분석 결과로 나온 중요단어가 얼마나 포함되어있는지를 계산 실제 국제에 포함된 키워드 상위 20개 단어 - 미국, 중국, 러시아, 우크라이나, 트럼프, 바이든, 캐나다, 한국, 대만, AI, 일본, 몬테네그로, 벨라루스, 쿠바, 영국, 유럽, 뉴욕, 백안관, 푸틴, WSJ 국제 카테고리 주요 키워드 상위 20개 단어 - 미국, 중국, 바이든, 우크라이나, 러시아, 트럼프, 캐나다, 일본, 한국, 쿠바, 푸틴, 대만, 기시다, 벨라루스, 영국, ai, 유럽, 몬테네그로, liv, pga
데이터 분석 평가 결과	국제 해당 기사의 평가 결과는 20개중 17개 포함 = 85 % 전체 해당 기사의 평가 결과는 20개중 17개 포함 = 85 % 정치 해당 기사의 평가 결과는 20개중 15개 포함 = 75 % 경제 해당 기사의 평가 결과는 20개중 15개 포함 = 75 % 사회 해당 기사의 평가 결과는 20개중 13개 포함 = 65 %

기능명	뉴스 요약 서비스
1. 데이터 준비	
데이터 정의	사용자 입력 데이터, 뉴스 데이터(뉴스 기사, 기자 정보, 출판사 정보, 뉴스 카테고리, 키워드), 사용자 프로필 데이터(사용자의 선호 카테고리, 이전 기록, 구독 정보)
데이터 획득 방법	신문사별 뉴스 하루 약 200개 정도 크롤링(총합 약 1000개) 한겨레(https://www.hani.co.kr/), 경향신문(https://www.khan.co.kr/), 중앙일보(https://www.joongang.co.kr/), 동아일보(https://www.donga.com/), 조선일보(https://www.chosun.com/)
수집 데이터	신문사, 날짜(YYYY-MM-DD), 카테고리(경제, 사회, 문화 등), 기사제목, 기사 내용

	press	category	title	date	reporter	content
	조선일보	경제	누누티비 차단 효과? 토종 OTT 앱 사용자 수 100만명 증가	2023.06.07	채재우 기자	[불법 동영상 스트리밍 사이트 누누티비가 국내 온라인 동영상 서비스(OTT)를 증...
	조선일보	경제	'이런 판기도 헛수고 하겠다' 대한 가에 불은 영준사 포스터	2023.06.07	김자아 기자	[국내 한 저비용항공사(LCC)가 대한항공을 대상으로 무로항공사권 행사를 진행하다...
	조선일보	경제	중대재해처벌법 위헌성 평가가 전심... 주 처벌 대상은 대표이사	2023.06.07	류정 기자	[중대재해처벌법에 따른 처벌의 한심 기준을 기업들이 자체적으로 위헌성 평가...
	조선일보	경제	한강뷰 아파트 59㎡가 8억7000만원... 이만 앞까 중등분양 쏟아진다	2023.06.07	신수지 기자	[시세보다 반 가격에 내 집 마련이 가능 한 강변북로 양천구의 출세 사전정착...
	조선일보	경제	'출원 끼워팔기' 효과? 유튜브유직, 웹시장이서 할 사용자 역대 최대	2023.06.07	김봉기 기자	[국내 출원서비스 업계에서 출원 끼워팔기 논란을 일으킨 구글 유튜브유직의...
	...	...	...	...	...	...
	경향신문	국제	'미 CIA, 우크라이나 해저가수관 공격 계획 3개월 전에 인지'	2023.06.07	선명수 기자	[미국 정부당국이 지난해 6월 발표해 해저 노르프스트림 가스관 폭발 사건 3개월...
	경향신문	국제	'이파네마의 소녀' 보사노바 가수 아스트루지 지우에르투 별세	2023.06.07	선명수 기자	[1980년대 '보사노바 열풍'을 일으킨 곡 '이파네마의 소녀(The Girl F...
	경향신문	국제	'지안 공백' 아이티, 폭우 이어 지진까지... 최소 55명 사망	2023.06.07	선명수 기자	[경단의 폭격과 전열물 확산으로 국심 한층난을 겪고 있는 중남미 카리브해의...
	경향신문	국제	미 '우크라이나' 폭격과 패배... 아진 단 정국... 나트 리안온은 토자	2023.06.07	선명수 기자	[미국이 6일(현지시간) 우크라이나 남부 흐르스쿠 카호우카섬 폭격의 패배를 인정...
	경향신문	국제	한국, 11년 만에 유엔 안보리 비상임이사국 선출	2023.06.07	정원식 기자	[한국은 6일(현지시간) 미국 뉴욕 유엔본부에서 열린 총회 비상임이사국 선거에서...
2. 전처리						
전처리 과정	1. 초기 크롤링 데이터를 mongoDB에 저장 2. 날짜별로 데이터를 불러옴 3. Dictionary 타입의 데이터를 DataFrame 타입으로 변환 4. kiwi라이브러리를 사용해서 기사 내용중 한국어 명사, 영어 단어, 한자만 추출					
전처리 데이터	전처리가 완료된 후의 데이터 볼륨 ['불법 동영상 스트리밍 사이트 누누티비 국내 온라인 동영상 서비스 OTT 종료 계획' 토종 OTT 사용자 이상', '빅데이터 분석 플랫폼 모바일 인덱스 티빙 쿠팡 플레이 웨이브 왓치 국내 OTT 개사 할간 활동 사용자 MAU 집계', ...] '모바일 시청자 분석 숫자 TV 플랫폼 규모 예상', '업계 추산 이용자 이상 누누티비 서비스 종료 영향', '서비스 시작 누누티비 도미니카공화국 해외 서버 국내 유료 OTT 지상파 신작 무료 제공', '정부 유관 기관 합동 수사 국제 공조 수사 확대 입장 서비스 종료', '업계 관계자 누누티비 시장 경쟁 과열 최근 국내 OTT 오리지널 콘텐츠 반출 독점 TV 프로그램 서비스 차별 집중 설명', '기간 종료 OTT 업체 사용자', '기준 넷플릭스 전월 대비 디즈니 플러스 감소', '넷플릭스 글로벌 이후 회계 콘텐츠 영향 물이'] - 총 1022개 데이터 각 데이터당 단어수 : 평균 591개					

3. 데이터 분석	
데이터 분석 목표	뉴스 기사 한줄 요약
데이터 분석 알고리즘	1. Tfidf로 각 기사에서 추출된 문장의 중요도 파악 - ngram_range = (1,2) 2. TextRank로 문장별 가중치 파악 3. 가중치가 높은 상위 5개의 문장 추출 4. KoBart를 사용해서 한 문장으로 요약 - KoBart 설명 적어주기 <제목> "경찰은 수감 5배" ... 해군 초급간부 730명, 해경 미적 <일문> [‘열악한 처우 등으로 군을 떠나는 초급 간부들도 늘고 있다.’, ‘하는 일은 비슷하지만 수당은 3-5배 많이 주는 경찰·소방청이나 경호업체·항공사 등 민간 기업으로 이직하는 경우가 많다.’, ‘군에 따르면, 2017년부터 5년간 해군 초급 간부 700여 명이 군복을 벗고 해양경찰이 됐다.’, ‘수년간 합정 주요 장비를 다른 육군인 군인역이 대거 유출된 것이다.’, ‘해군에선 당장 합정 조타를 잡을 부사관이 부족해 급히 인원 충원을 하느라 애를 먹는 일이 속출했다고 한다.’, ‘5년 차 육군 위관급 장교 전역자도 2020년 34명에서 2021년 117명, 2022년 131명이 돼 3-4배도 급증한 것으로 파악됐다.’, ‘이들이 조기 전역한 주요 원인은 ‘불합리한 급여 제도’로 분석됐다.’, ‘경찰·소방 공무원과 하는 일은 비슷한데 급여는 적게 받는다는 것이다.’, ‘경우 자료를 보면, 군인 당직 근무비는 평일 1만원, 휴일 2만원이지만 경찰 공무원은 각각 3만원, 10만원이었다.’, ‘소방 공무원 평일 5만원, 휴일 10만원으로 군인에 비해 최대 5배 많은 수당을 받았다.’, ‘초급 간부 다수가 ‘지원’ 매달지만 비무장지대(DMZ) 등 최전방에 배치돼 군무를 시는데 유사 직종 다른 공무원은 물론 일반 공무원보다도 현저하게 낮은 수당을 받는 것이다.’, ‘이는 경찰 등은 ‘현업 공무원’으로 분류돼 초과 근무시간만큼 현액 수당을 받지만, 군인은 ‘비현업 공무원’이기 때문에 1개월에 100시간 근무하더라도 67시간만 수당으로 받고 나머지 시간엔 받지 못하는 제도적 문제 때문에 분석된다.’, ‘공무원 복무 규정상 ‘비현업 공무원’은 초과근무 수당을 제한하고 있다.’, ‘3년 이상 복무한 하사·중령 이하 군인에게 지급하는 주택 수당도 26년간 돌궐내 현재 월 8만원에 불과한 것으로 알려졌다.’, ‘군부지를 자주 옮겨야 하는 초급 간부들의 경우 군 숙소를 배정받지 못해 주택 수당으로 생활권을 구해 살아야 하는데, 월 8만원으로는 턱없이 부족해 자기 월급으로 충당해야 하는 것이다.’, ‘군은 이와 관련한 불만이 커지자 최근 주택 수당을 월 16만원으로 2배로 인상하기로 급히 결정하는 것으로 알려졌다.’, ‘군 관계자는 “예산 확보를 통해 각종 수당을 적정 수준으로 인상할 방침”이라고 말했다.’] <TextRank + koBart 요약> 2017년부터 5년간 해군 초급 간부 700여 명이 군복을 벗고 해양경찰이 됐는데, 이는 경찰·소방 공무원과 하는 일은 비슷한데 급여는 적게 받는다는 이유로 군인에 비해 최대 5배 많은 수당을 받는 제도적 문제 때문에 분석된다. <키워드> [‘수당’, ‘공무원’, ‘군무’, ‘군인’, ‘경찰’, ‘주택’, ‘주택 수당’, ‘초급 간부’, ‘간부’, ‘초급’, ‘제도’, ‘분석’, ‘부족’, ‘경우’, ‘현업’]
4. 검증	
데이터 분석 검증 방안	Dacon 한국어 문서 생성요약 AI 경진대회의 데이터 참고 - Precision은 정밀도, Recall은 재현율, F1는 score를 뜻하며 실험 혹은 예측을 제대로 했는지를 확인하기 위하여 사용되는 지표 중 하나이다. - ROUGE는 generation task를 평가하기 위해 사용되는 대표적인 Metric이다. rouge는 n-gram Recall에 기반하여 계산하게 되며 $ROUGE-N = \frac{\sum_{S \in \{Reference\ Summaries\}} \sum_{gram_n \in S} Count_{match}(gram_n)}{\sum_{S \in \{Reference\ Summaries\}} \sum_{gram_n \in S} Count(gram_n)}$ 위의 식은 reference summary(정답 summary)와 생성된 summary사이의 n-gram recall을 의미한다.

rouge-1, rouge-2, rouge-l은 rouge의 variation 중 일부로 이를 통하여 데이터 분석을 시행한다.

ROUGE-1의 경우 unigram

정답문장: "한화는 10 년 안에 우승 할 것이다."

생성문장: "두산은 3 년 안에 우승 할 것이다."

$$N_{\text{정답문장}} = 7$$

$$N_{\text{년,안,우승,할,것이다}} = 5$$

$$ROUGE-1 = \frac{5}{7}$$

예시와 같이 문장의 5/7이 베이스로 문장이 생성된다.

ROUGE-2의 경우 bigram

정답문장: "한화는 10 년 안에 우승 할 것이다."

생성문장: "한화는 10 년 안에 절대 우승 못 할 것이다. "

$$N_{\text{정답문장}} = 6$$

$$N_{((\text{한화},10),(\text{10},\text{년}),(\text{년},\text{안}),(\text{안},\text{할}),(\text{할},\text{것이다}))} = 4$$

$$ROUGE-2 = \frac{4}{6}$$

예시와 같이문장의 4/6이 베이스로 문장이 생성된다.

ROUGE-l은 Longest Common Subs equence, 가장 긴 Sequence 의 recall을 구하며 Sequence는 이어지지 않아도 된다.

정답문장 "한화는 10 년 안에 우승 할 것이다."

생성문장: "한화는 10 년 안에 절대 우승 못 할 것이다. "

$$N_{\text{정답문장}} = 7$$

longest_sequence = 한화는 10 년 안에 우승 할 것이다

$$N_{\text{longest_sequence}} = 7$$

$$ROUGE-L = \frac{7}{7} = 1$$

생성된 문장의 예시와 정답문장이 완전히 일치하지는 않지만, 떨어져 있는 Sequence 형태로 정답문장과 일치하기 때문에 1의 ROUGE-L score를 얻는다.

